

PARK SEO-YUN / 합성 프로필

Data Platform Engineer · Earth Observation

PRIZM P7-A v2 synthetic resume — 실제 인물·기관·위성 자료와 무관

대규모 위성 영상 batch에서 대기 작업, 손상 입력, skew partition과 재처리 의미를 분리해 다루는 가상 데이터 엔지니어. Python API부터 Airflow orchestration, Spark 계산, Delta 품질 경계까지 연결한다.

6.4TB maximum daily imagery	138 → 41 min mosaic pipeline	9.6M scene backfill	64 corrupt GeoTIFF quarantined
---------------------------------------	--	-------------------------------	--

DATA PLATFORM EXPERIENCE

Synthetic Orbital Analytics · Data Platform Engineer

2023.02 - 2026.05 | OrbitMosaic

촬영 궤도별 GeoTIFF를 검증하고 일 단위 모자이크와 검색용 metadata를 만드는 pipeline을 담당했다. Python/FastAPI 입력 계약, Airflow scheduling, Spark transform, Delta Lake revision 모델을 한 흐름으로 운영했다.

- FastAPI manifest endpoint에서 scene_id, revision, orbit, checksum, object URI 검증
- Airflow deferrable operator로 object-ready event 대기 중 worker slot 반환
- acquisition_date-orbit partition과 Spark adaptive query execution으로 skew 완화
- Delta MERGE의 scene_id + revision key로 동일 revision 재전송 중복 차단

Measured outcomes

동일 40-node 조건

최대 6.4TB 일일 입력의 end-to-end 시간을 138분에서 41분으로 줄였다. 9,600,000개 scene metadata backfill에서 active row 중복은 0건이었으며 날짜 범위 checkpoint로 중단 지점부터 재개했다.

- 작은 중간 파일을 모자이크 완료 시 병합
- executor 손실-object 지연·품질 오류를 별도 retry 정책으로 분리
- 성능 결과에 quarantine 재전송 시간은 포함하지 않음

Input quality gate

8,750 delivery package validation

checksum 또는 TIFF directory가 손상된 GeoTIFF 64개를 quarantine table과 별도 object prefix로 옮겼다. 격리 scene은 모자이크와 공개 catalog에 들어가지 못하며 재전송 ticket을 추적했다.

- 오류 scene 단위 격리로 정상 package 내용은 보존
- 원본 checksum과 발견 단계 기록
- 재수신 뒤 revision-checksum을 다시 검증

PARK SEO-YUN / 합성 프로필 / Data Platform Engineer · Earth Observation

PRIZM P7-A v2 synthetic resume — 실제 인물·기관·위성 자료와 무관

OPERATIONS, TOOLS & BOUNDARIES

CloudCal · Data Tooling Engineer

2021.08 - 2023.01 | calibration support

분석가가 작은 보정 표본을 로컬에서 검토할 수 있도록 DuckDB export와 품질 report를 제공했다. 이 workload는 OrbitMosaic의 Spark 처리량과 분리를 측정했다.

- schema drift report와 sample lineage 생성
- 분석 notebook용 read-only snapshot 배포
- 재현 가능한 calibration parameter bundle 관리

Operational ownership

실행보다 실패 분류를 먼저

on-call runbook을 object-not-ready, checksum mismatch, executor loss, Delta conflict로 나눴다. 같은 retry로 모든 오류를 숨기지 않고 각 경계의 소유자와 종료 조건을 기록했다.

- Airflow task duration과 deferred duration 분리
- Spark stage skew dashboard
- quarantine aging 및 재전송 SLA 관측

Technical profile

synthetic skills

Python · FastAPI · Pytest · Airflow · Spark SQL · Delta Lake를 중심으로 작업했다. 데이터 계약은 JSON Schema와 property-based test로 검증했다.

- DuckDB · GeoTIFF metadata · object storage
- structured event log · OpenLineage concepts
- backfill rehearsal · checkpoint recovery

Explicit scope boundaries

검토와 구현을 구분

Dask는 로컬 prototype 30건 비교에만 사용했고 production scheduler나 계산 엔진으로 채택하지 않았다. 외부 cloud mask model의 inference output은 소비했지만 객체 탐지 또는 cloud model을 직접 학습하지 않았다.

- production orchestration: Airflow
- production distributed compute: Spark