

SYN-U02 · DATA PIPELINE RESUME

PRIZM P7 synthetic profile — 실제 인물·기관·검체와 무관

1.8 TB daily sequencing batch	94 → 26 min end-to-end validation	317 / 12,600 checksum quarantine / manifests	2.4 M exact-once backfill records
---	---	--	---

GeneTrail QC

Python과 FastAPI로 sample manifest 접수 API를 만들고, Airflow가 검증 단계를 조정하도록 구성했다.

Spark partition 재구성과 작은 파일 병합으로 1.8TB 일일 batch의 처리 시간을 94분에서 26분으로 줄였다.

Data correctness

Delta Lake MERGE는 lab-batch와 sample-id를 복합 키로 사용했다. 2,400,000개 record를 다시 적재해도 중복 결과가 생기지 않았다.

manifest checksum 오류 317건은 격리 영역으로 이동시켜 분석 테이블과 섞이지 않게 했다.

Operational boundary

sequencer gateway 보호를 위해 Airflow pool 동시 실행을 12개 task로 제한했다. Apache Iceberg는 비교 검토만 했으며 운영 포맷으로 채택하지 않았다.